

در این بخش ابتدا دیتاست مورد نظر که شامل نظرات مختلف کالا ها به همراه امتیاز ثبت شده برای هر کدام است را خوانده و به صورت زیر چند سطر از آن را نمایش می دهیم :

| Unnamed: 0 | Clothing ID | Age  | Title |                         | Review Text                                       | Rating | Recommended IND | Positive Feedback Count | Division Name  | Department Name | Class Name |
|------------|-------------|------|-------|-------------------------|---------------------------------------------------|--------|-----------------|-------------------------|----------------|-----------------|------------|
| 0          | 0           | 787  | 33    | NaN                     | Absolutely wonderful - silky and sexy and comf... | 4      | 1               | 0                       | Intimates      | Intimate        | Intimates  |
| 1          | 1           | 1080 | 34    | NaN                     | Love this dress! it's sooo pretty. i happene...   | 5      | 1               | 4                       | General        | Dresses         | Dresses    |
| 2          | 2           | 1077 | 60    | Some major design flaws | I had such high hopes for this dress and reali... | 3      | 0               | 0                       | General        | Dresses         | Dresses    |
| 3          | 3           | 1049 | 50    | My favorite buy!        | I love, love, love this jumpsuit. it's fun, fl... | 5      | 1               | 0                       | General Petite | Bottoms         | Pants      |
| 4          | 4           | 947  | 47    | Flattering shirt        | This shirt is very flattering to all due to th... | 5      | 1               | 6                       | General        | Tops            | Blouses    |

برای شروع پیش پردازش ابتدا بررسی می کنیم که مقدار Null در دیتاست به خصوص در ستون های Rating و Review Text وجود نداشته باشد :

```
[ ] # Check null value
data.isnull().sum()
```

|                         |      |
|-------------------------|------|
|                         | 0    |
| Unnamed: 0              | 0    |
| Clothing ID             | 0    |
| Age                     | 0    |
| Title                   | 3810 |
| Review Text             | 845  |
| Rating                  | 0    |
| Recommended IND         | 0    |
| Positive Feedback Count | 0    |
| Division Name           | 14   |
| Department Name         | 14   |
| Class Name              | 14   |

همانطور که قابل مشاهده است ، در ستون Review Text تعداد ۸۴۵ تا مقدار Null وجود دارد .

برای رفع این مشکل ستون هایی که مقادیر آن ها Null هستند را حذف می کنیم و همزمان عمل lower case کردن و حذف کاراکتر های خاص (علامت تعجب ، علامت سوال و ...) را با استفاده از قطعه کد زیر انجام می دهیم :

```
# Step 1: Drop rows with missing values in critical columns (Review Text and Rating)
data_cleaned = data.dropna(subset=['Review Text', 'Rating'])

# Step 2: Clean the Review Text column (lowercasing, removing special characters)
import re

def clean_text(text):
    text = text.lower() # Convert text to lowercase
    text = re.sub(r'^a-zA-Z\s]', '', text) # Remove special characters and numbers
    return text

data_cleaned['Cleaned Review Text'] = data_cleaned['Review Text'].apply(clean_text)

data_cleaned.head()
```

| Unnamed: 0 | Clothing ID | Age  | Title | Review Text                                                              | Rating | Recommended IND | Positive Feedback Count | Division Name  | Department Name | Class Name | Cleaned Review Text                               |
|------------|-------------|------|-------|--------------------------------------------------------------------------|--------|-----------------|-------------------------|----------------|-----------------|------------|---------------------------------------------------|
| 0          | 0           | 767  | 33    | High Absolutely wonderful - silky and sexy and comfy...                  | 4      | 1               | 0                       | Intimates      | Intimates       | Intimates  | absolutely wonderful silky and sexy and comfy...  |
| 1          | 1           | 1080 | 34    | High Love this dress! It's sooo pretty. I happened...                    | 5      | 1               | 4                       | General        | Dresses         | Dresses    | love this dress its sooo pretty i happened t...   |
| 2          | 2           | 1077 | 60    | Some major design flaws I had such high hopes for this dress and real... | 3      | 0               | 0                       | General        | Dresses         | Dresses    | i had such high hopes for this dress and real...  |
| 3          | 3           | 1049 | 50    | My favorite buy! I love, love, love this jumpsuit. It's fun, fl...       | 5      | 1               | 0                       | General Petite | Bottoms         | Pants      | i love love love this jumpsuit its fun flirty ... |
| 4          | 4           | 847  | 47    | Flattering shirt This shirt is very flattering to all due to th...       | 5      | 1               | 6                       | General        | Tops            | Blouses    | this shirt is very flattering to all due to th... |

پس از اجرای این قطعه کد می توانید مشاهده کنید که تعداد Null ها در ستون Review Text به صفر می رسد :

|                         |      |
|-------------------------|------|
| Unnamed: 0              | 0    |
| Clothing ID             | 0    |
| Age                     | 0    |
| Title                   | 2966 |
| Review Text             | 0    |
| Rating                  | 0    |
| Recommended IND         | 0    |
| Positive Feedback Count | 0    |
| Division Name           | 13   |
| Department Name         | 13   |
| Class Name              | 13   |
| Cleaned Review Text     | 0    |


به عنوان بخش دیگری از پیش پردازش ، یک سری از ویژگی ها را در این دیتاست بررسی می کنیم .

۱. مجموع تعدادی که از هر Rate وجود دارد را نمایش می دهیم :


```
data_cleaned["Rating"].value_counts()
```

| count  |       |
|--------|-------|
| Rating |       |
| 5      | 12540 |
| 4      | 4908  |
| 3      | 2823  |
| 2      | 1549  |
| 1      | 821   |

نتیجه ی این بررسی به صورت گرافیکی در زیر نشان داده شده است :



و نحوه ی توزیع این Rating ها روی کل دیتاست به صورت زیر است :



٢. حذف StopWord ها :

```
[ ] from nltk.corpus import stopwords
import nltk

# Download stopwords if not already available
nltk.download('stopwords')

# Get the list of English stopwords
stop_words = set(stopwords.words('english'))


# Function to remove stopwords from text
def remove_stopwords(text):
    words = text.split()
    filtered_words = [word for word in words if word not in stop_words]
    return ' '.join(filtered_words)

# Apply the function to the Cleaned Review Text column
data_cleaned['Cleaned Review Text'] = data_cleaned['Cleaned Review Text'].apply(remove_stopwords)

data_cleaned.head()
```

| Unnamed: 0 | Clothing ID | Age  | Title | Review Text                                                               | Rating | Recommended (NO) | Positive Feedback Count | Division Name  | Department Name | Class Name | Cleaned Review Text                               |
|------------|-------------|------|-------|---------------------------------------------------------------------------|--------|------------------|-------------------------|----------------|-----------------|------------|---------------------------------------------------|
| 0          | 0           | 797  | 33    | Nah! Absolutely wonderful - silky and comfy and conf...                   | 4      | 1                | 0                       | Intimates      | Intimates       | Intimates  | absolutely wonderful silky comfy comfortable      |
| 1          | 1           | 1080 | 34    | Nah! Love this dress! it's sooo pretty. I happened...                     | 5      | 1                | 4                       | General        | Dresses         | Dresses    | love dress sooo pretty happened find store in     |
| 2          | 2           | 1077 | 60    | Some major design flaws. I had such high hopes for this dress and real... | 3      | 0                | 0                       | General        | Dresses         | Dresses    | high hopes dress really wanted work initially     |
| 3          | 3           | 1049 | 50    | My favorite buy! I love, love, love this jumpsuit. It's fun, fi...        | 5      | 1                | 0                       | General Petite | Bottoms         | Pants      | love love love jumpsuit fun flirty fabulous ev... |
| 4          | 4           | 847  | 47    | Flattering short This short is very flattering to all due to th...        | 5      | 1                | 0                       | General        | Tops            | Blouses    | short flattering due adjustable front fit perf... |

۳. به صورت Word Cloud کلمات مهم و پرتکراری که در هر Rate تکرار شده اند را نمایش می دهیم :



پس از انجام پیش پردازش های لازم ، کلمات ورودی به مدل را باید به بردار های Embedding تبدیل کنیم . برای این کار از Embedding های آماده ی Glove و فضای ۶ میلیارد کلمه و ۱۰۰ بعدی استفاده کردیم :

```
# Prepare Glove
embeddings_index = {}
with open("/content/gdrive/MyDrive/Glove/glove.6B.100d.txt", encoding="utf-8") as f:
    for line in f:
        values = line.split()
        word = values[0]
        coefs = np.asarray(values[1:], dtype='float32')
        embeddings_index[word] = coefs

# Processing the embedding text
tokenizer = Tokenizer()
tokenizer.fit_on_texts(train['Cleaned Review Text'])
sequences = tokenizer.texts_to_sequences(train['Cleaned Review Text'])

word_index = tokenizer.word_index
max_len = 100 # حداکثر طول دنباله ها
data = pad_sequences(sequences, maxlen=max_len)
```

همانطور که مشاهده می کنید ، به هر کلمه ی ورودی ۱۰۰ عدد به عنوان بردار اختصاص داده شده است :

```
[ ] print(f"Input data shape: {data.shape}")
```

```
Input data shape: (15847, 100)
```

پس از انجام Embedding ، مدل LSTM خود را طراحی می کنیم و آن را آموزش می دهیم :

```
# 5. Build the LSTM model
input_layer = Input(shape=(max_len,), dtype='int32')
embedding_layer = Embedding(input_dim=num_words,
                             output_dim=embedding_dim,
                             weights=[embedding_matrix],
                             input_length=max_len,
                             trainable=False)(input_layer)

lstm1 = LSTM(128, return_sequences=True)(embedding_layer)
dropout1 = Dropout(0.2)(lstm1)
lstm2 = LSTM(64, return_sequences=False)(dropout1)
dropout2 = Dropout(0.2)(lstm2)
output_layer = Dense(1, activation='linear')(dropout2)

model = Model(inputs=input_layer, outputs=output_layer)

# Compile the model
model.compile(optimizer='adam', loss='mean_squared_error', metrics=['mae'])

# Display the model structure
model.summary()

# 6. Train the model
y = train['Rating'].values
model.fit(data, y, batch_size=32, epochs=50, validation_data=(X_val, y_val))

# 7. Make predictions on validation data
y_pred_val = model.predict(X_val)

# 8. Evaluate performance on validation data
mae_val = mean_absolute_error(y_val, y_pred_val)
rmse_val = np.sqrt(mean_squared_error(y_val, y_pred_val))

print(f"Validation Mean Absolute Error (MAE): {mae_val}")
print(f"Validation Root Mean Squared Error (RMSE): {rmse_val}")
```

**لایه اول LSTM :** `return_sequences=True` تنظیم شده تا دنباله کامل از بردارها برای لایه بعدی برگردانده شود.

**لایه دوم LSTM :** `return_sequences=False` تنظیم شده تا فقط بردار خروجی نهایی (خلاصه دنباله) برگردانده شود.

**Dropout:** به منظور کاهش Overfitting بین لایه ها اضافه شده است.

**لایه Dense :** خروجی نهایی یک عدد است که امتیاز پیش بینی شده را ارائه می دهد.

تعداد پارامتر های مدل و ابعاد خروجی هر لایه به صورت زیر است :

| Layer (type)               | Output Shape     | Param #   |
|----------------------------|------------------|-----------|
| input_layer_6 (InputLayer) | (None, 100)      | 0         |
| embedding_6 (Embedding)    | (None, 100, 100) | 1,503,300 |
| lstm_12 (LSTM)             | (None, 100, 128) | 117,248   |
| dropout_12 (Dropout)       | (None, 100, 128) | 0         |
| lstm_13 (LSTM)             | (None, 64)       | 49,408    |
| dropout_13 (Dropout)       | (None, 64)       | 0         |
| dense_6 (Dense)            | (None, 1)        | 65        |

## Output Shape

شکل خروجی هر لایه :

(None, 100) : None نشان دهنده تعداد نمونه های نامشخص (batch size) است که به صورت پویا تعریف شده است ، و 100 نشان دهنده طول ورودی لایه (max\_len) است.

(None, 100, 100) : خروجی لایه Embedding شامل بردارهای Embedd شده با ابعاد ۱۰۰ برای هر کلمه است.

(None, 100, 128) : خروجی لایه LSTM اول که برای هر کلمه ۱۲۸ مقدار تولید می کند.

(None, 64) : خروجی لایه LSTM دوم که بردار نهایی با طول ۶۴ است.

(None, 1) : خروجی لایه Dense که یک مقدار عددی برای پیش بینی ارائه می دهد.

## Parameters

تعداد پارامترهای قابل آموزش هر لایه :

Embedding : تعداد کلمات  $\times$  اندازه بردار تعبیه (در اینجا  $1,503,300$ ).

LSTM ها: تعداد واحدها  $\times$  (تعداد ورودی + تعداد واحدهای قبلی + ۱ بایاس).


Dense : تعداد واحدها (۱)  $\times$  تعداد ورودی (۶۴) + ۱ بایاس (در اینجا ۶۵).



مدل طراحی شده را آموزش دادیم و عملکرد آن را با استفاده از معیار های MAE و RMSE بررسی کردیم که نتایج آن به صورت زیر است :

Validation Mean Absolute Error (MAE): 0.5541714429855347  
Validation Root Mean Squared Error (RMSE): 0.8422742583081214

همچنین نمودار پراکندگی هم برای این مدل رسم کردیم که به شکل زیر است :



نمودار پراکندگی ارائه شده، مقایسه ای بین امتیازات واقعی (Actual Ratings) و امتیازات پیش بینی شده (Predicted Ratings) را نشان می دهد. نقاط آبی نشان دهنده نمونه ها هستند و خط قرمز (خط مرجع) نشان دهنده حالتی است که پیش بینی ها کاملاً منطبق بر مقادیر واقعی هستند (یعنی  $y_{pred} = y_{actual}$ ).

در بیشتر نقاط، پیش بینی مدل به امتیازات واقعی نزدیک است، به ویژه برای مقادیر میانی (مانند ۳ و ۴). این نشان می دهد که مدل در این محدوده عملکرد مناسبی دارد.

در مقادیر کم (۱) و زیاد (۵)، پراکندگی بیشتری وجود دارد. این به این معناست که مدل در پیش بینی امتیازات انتهایی (خیلی کم یا خیلی زیاد) عملکرد ضعیف تری دارد. ممکن است دلیل این مسئله عدم تعادل داده ها (تعداد کمتر نمونه ها برای امتیازهای ۱ و ۵) باشد.

برخی از نقاط فاصله زیادی از خط مرجع دارند، که نشان‌دهنده خطای مدل در پیش‌بینی است. این نقاط می‌توانند نمونه‌هایی باشند که مدل نتوانسته به‌درستی یاد بگیرد.

مقادیر MAE و RMSE برای داده‌های تست هم محاسبه شده است که به صورت زیر می‌باشد :

```
Test Mean Absolute Error (MAE): 0.5434132218360901
Test Root Mean Squared Error (RMSE): 0.8372115649117594
```

در بخش بعدی بلوک های LSTM را با BiLSTM جایگزین می کنیم .

برای جایگزینی لایه های LSTM با Bidirectional LSTM (BiLSTM) ، کافی است از کلاس Bidirectional در TensorFlow/Keras استفاده کنیم . این لایه دو نسخه از LSTM (یکی در جهت مستقیم و دیگری در جهت معکوس) ایجاد می کند و خروجی های هر دو را ترکیب می کند.

با قطعه کد زیر این مدل را پیاده سازی کردیم :

```
# 5. Building the BiLSTM model
input_layer = Input(shape=(max_len,), dtype='int32') # Input layer for sequences
embedding_layer = Embedding(input_dim=num_words,
                             output_dim=embedding_dim,
                             weights=[embedding_matrix],
                             input_length=max_len,
                             trainable=False)(input_layer) # Embedding layer with pre-trained weights

# First BiLSTM layer
bilstm1 = Bidirectional(LSTM(128, return_sequences=True))(embedding_layer) # BiLSTM with 128 units
dropout1 = Dropout(0.2)(bilstm1) # Dropout for regularization

# Second BiLSTM layer
bilstm2 = Bidirectional(LSTM(64, return_sequences=False))(dropout1) # BiLSTM with 64 units
dropout2 = Dropout(0.2)(bilstm2) # Dropout for regularization

# Dense layer for the output
output_layer = Dense(1, activation='linear')(dropout2) # Linear activation for regression

model = Model(inputs=input_layer, outputs=output_layer) # Create the model

# Compile the model
model.compile(optimizer='adam', loss='mean_squared_error', metrics=['mae']) # Use MSE loss and MAE metric

# Display model structure
model.summary()

# 6. Training the model
y = train['Rating'].values # Extract ratings as target variable
model.fit(data, y, batch_size=32, epochs=50, validation_data=(X_val, y_val)) # Train the model

# 7. Making predictions on the validation data
y_pred_val = model.predict(X_val)

# 8. Evaluating performance on validation data
mae_val = mean_absolute_error(y_val, y_pred_val) # Calculate MAE
rmse_val = np.sqrt(mean_squared_error(y_val, y_pred_val)) # Calculate RMSE
```


لایه های مدل جدید مانند مدل قبلی است فقط با این تفاوت که از BiLSTM استفاده می کند که می تواند روابط بین کلمات در هر دو جهت (چپ به راست و راست به چپ) را یاد بگیرد. این معمولاً باعث بهبود عملکرد مدل در وظایف متنی می شود.

تعداد پارامتر های مدل و ابعاد خروجی هر لایه هم به صورت زیر است :

| Layer (type)                    | Output Shape     | Param #   |
|---------------------------------|------------------|-----------|
| input_layer (InputLayer)        | (None, 100)      | 0         |
| embedding (Embedding)           | (None, 100, 100) | 1,503,300 |
| bidirectional (Bidirectional)   | (None, 100, 256) | 234,496   |
| dropout (Dropout)               | (None, 100, 256) | 0         |
| bidirectional_1 (Bidirectional) | (None, 128)      | 164,352   |
| dropout_1 (Dropout)             | (None, 128)      | 0         |
| dense (Dense)                   | (None, 1)        | 129       |

مقادیر MAE و RMSE و نمودار پراکندگی را برای این مدل در زیر مشاهده می کنید :

Validation Mean Absolute Error (MAE): 0.5503838658332825  
Validation Root Mean Squared Error (RMSE): 0.8231881011898136



مقادیر MAE و RMSE برای داده های تست به صورت زیر است :

```
Test Mean Absolute Error (MAE): 0.5395618677139282
Test Root Mean Squared Error (RMSE): 0.8192987626818702
```

## مزایا و معایب مدل های LSTM و BiLSTM :

بلوک BiLSTM (Bidirectional LSTM) نسبت به LSTM مزایا و معایب زیر را دارد:

### مزایا:

#### دسترسی به اطلاعات آینده و گذشته:

BiLSTM متن ورودی را از دو جهت (از ابتدا به انتها و از انتها به ابتدا) پردازش می کند. این ویژگی به مدل امکان می دهد تا نه تنها از اطلاعات قبلی، بلکه از اطلاعات آینده نیز برای پیش بینی استفاده کند. این امر به ویژه در پردازش زبان طبیعی مفید است که کلمات آینده می توانند تأثیر مهمی بر معنای متن داشته باشند.

### بهبود دقت:

در مسائلی مانند ترجمه ماشینی، تحلیل احساسات و تشخیص گفتار، BiLSTM معمولاً دقت بالاتری در پیش بینی دارد، زیرا اطلاعات کامل تری از ترتیب داده ها در اختیار دارد.

با توجه به مدل هایی که ما طراحی کردیم ، این بهبود دقت به وضوح قابل مشاهده است .

مقادیر MAE و RMSE برای داده های تست در مدل LSTM :

```
Test Mean Absolute Error (MAE): 0.5434132218360901
Test Root Mean Squared Error (RMSE): 0.8372115649117594
```

مقادیر MAE و RMSE برای داده های تست در مدل BiLSTM :

```
Test Mean Absolute Error (MAE): 0.5395618677139282
Test Root Mean Squared Error (RMSE): 0.8192987626818702
```

## درک روابط پیچیده‌تر:

از آنجا که مدل به دو جهت داده‌ها نگاه می‌کند، روابط پیچیده‌تر در داده‌ها را بهتر درک می‌کند.

## معایب:

### افزایش هزینه محاسباتی:

چون BiLSTM داده‌ها را در هر دو جهت پردازش می‌کند، تعداد پارامترها و محاسبات افزایش می‌یابد. این موضوع باعث افزایش زمان آموزش و نیاز به منابع سخت‌افزاری بیشتری می‌شود.

### نیاز به داده‌های کامل در هنگام پردازش آنلاین:

برخلاف LSTM که می‌تواند در لحظه داده‌های جدید را پردازش کند، BiLSTM به کل دنباله نیاز دارد تا بتواند اطلاعات را از دو جهت پردازش کند. این موضوع باعث می‌شود استفاده از BiLSTM در کاربردهای real-time محدودتر باشد.

### پیچیدگی بیشتر مدل:

به دلیل دو برابر شدن تعداد LSTM ها، مدل BiLSTM پیچیده‌تر از LSTM است و ممکن است به داده‌های بیشتری برای جلوگیری از overfitting نیاز داشته باشد.